

Projet de Data Science

Analyse et Prévision de la Consommation Électrique

Réalisé par :

- Othmane Ouzzine
- Zaynab EL moudni
- Hajar Bouzid
- Hakkou mouataz

Encadré par : M. Yasser El Alami

Classe : 1ère Année Master Ingénierie des Systèmes Informatiques (ISI) –Hybride

Établissement : SUPMTI RABAT

Année universitaire : 2025/2026

Le : 01/02/2026

Objectif du Projet

Ce projet de data science a pour but d'étudier et analyser les tendances de consommation énergétique à partir de données réelles. Les objectifs principaux sont :

- Comprendre la structure des données de consommation électrique •
Identifier les tendances et relations importantes entre les variables
- Construire des modèles prédictifs pour prévoir la consommation totale (`totalkW_mean`) •
Communiquer clairement les résultats et recommandations

Type de problème : Régression (variable cible numérique continue)

Variable cible : `totalkW_mean` (consommation totale moyenne en kW)

Dataset

- **Source :** Données de consommation électrique quotidienne
- **Taille :** 600 lignes, 34 colonnes
- **Période :** Juin 2018 à 2020
- **Variables :** Mesures de consommation de plusieurs compteurs (53, 71, 71A, 83), données météorologiques (température, humidité, isolation), et variables temporelles

Structure du Projet

```
.
├── data/
│   ├── raw/                      # Données brutes
│   ├── processed/                # Données nettoyées et préparées
│   └── external/                 # Données externes
├── notebooks/
│   ├── 01_collecte_donnees.ipynb
│   ├── 02_analyse_exploratoire_EDA.ipynb
│   ├── 03_preparation_donnees.ipynb
│   └── 04_modelisation.ipynb
└── src/                         # Modules Python réutilisables
    ├── data_processing.py
    ├── evaluation.py
    ├── models.py
    └── visualization.py
├── models/                       # Modèles entraînés sauvegardés (.pkl)
├── visualizations/               # Graphiques générés
├── reports/                      # Rapports et résultats
├── presentation/                 # Support de présentation
└── requirements.txt              # Dépendances Python
```

1. Collecte des Donnees ([01_collecte_donnees.ipynb](#))

Ce notebook est dedie au chargement initial et a l'exploration preliminaire du dataset. Il couvre :

- **Chargement du dataset** : Lecture du fichier CSV contenant 600 observations et 34 variables
- **Apercu des donnees** : Affichage des premieres lignes pour comprendre la structure
- **Informations generales** : Types de variables (22 float, 5 int, 7 string), utilisation memoire (0.34 MB)
- **Statistiques descriptives** : Resume statistique de toutes les variables numeriques
- **Analyse des valeurs manquantes** : Detection des colonnes avec des valeurs manquantes
`(insolation: 44.5%, totalkW_w-1 et totalkW_w/1: 1.17%, totalkW_d-1 et totalkW_d/1: 0.17%)`
- **Verification des doublons** : Aucun doublon detecte
- **Cardinalite des variables categorielles** : Analyse du nombre de valeurs uniques par colonne
- **Sauvegarde** : Export du dataset brut pour les etapes suivantes

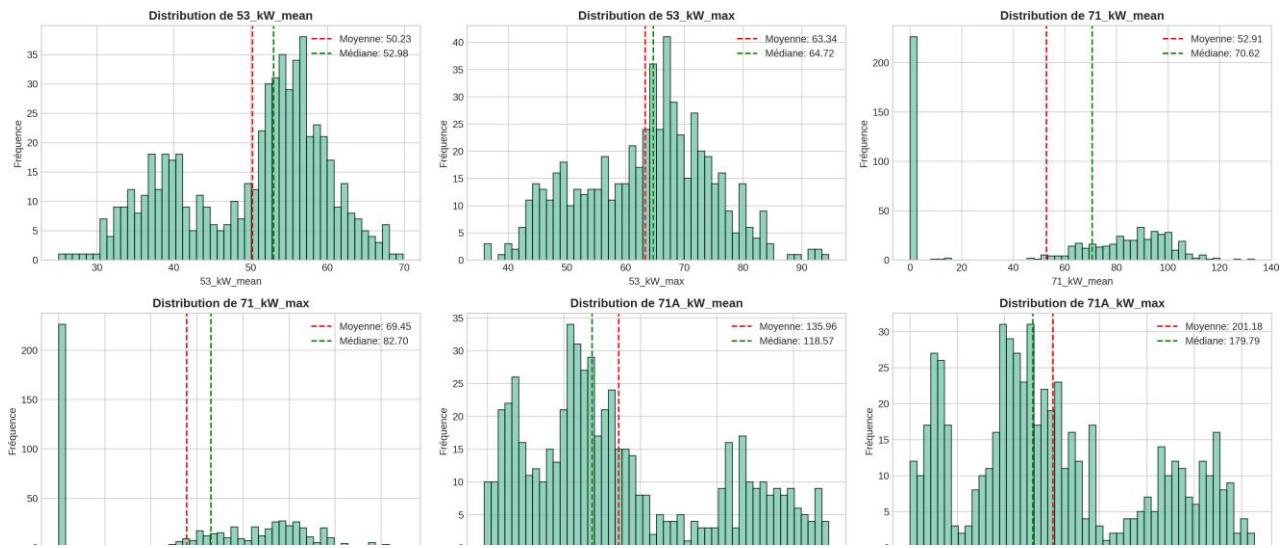
2. Analyse Exploratoire des Donnees - EDA ([02_analyse_exploratoire_EDA.ipynb](#))

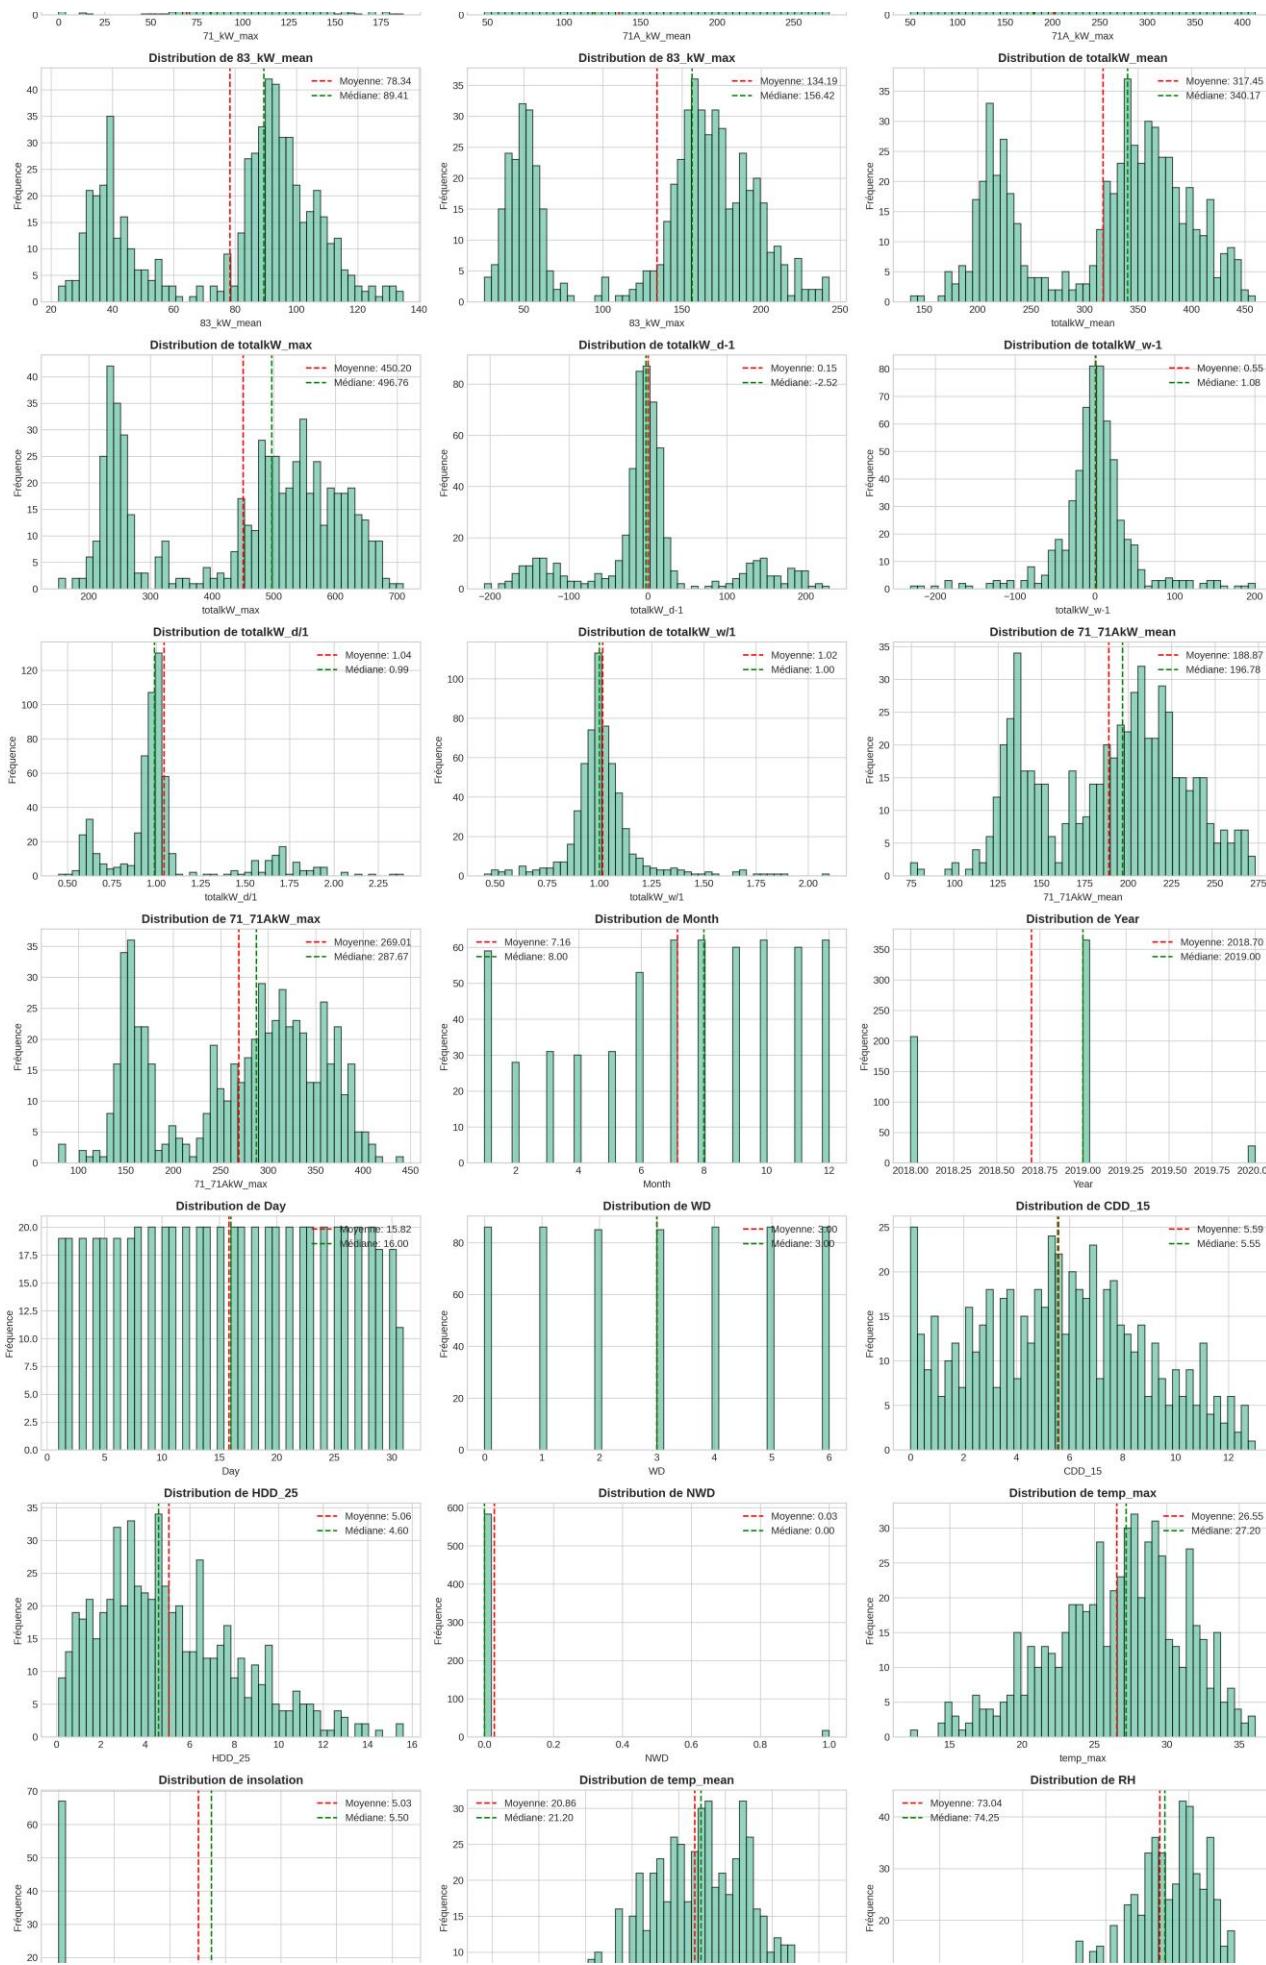
Ce notebook realise une analyse approfondie des donnees pour identifier des tendances et formuler des hypotheses. Il comprend :

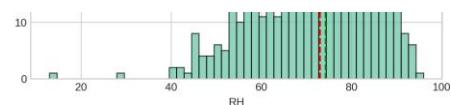
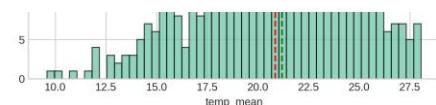
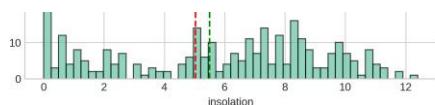
- **Statistiques descriptives avancees** : Calcul de la variance, asymetrie (skewness) et aplatissement (kurtosis) pour chaque variable
- **Analyse de l'asymetrie** : Identification des distributions asymetriques a droite (71A_kW_mean, HDD_25, NWD) et a gauche (RH)
- **Distributions des variables** : Histogrammes de toutes les variables numeriques avec moyenne et mediane
- **Detection des outliers** : Boxplots avec comptage des outliers par la methode IQR
- **Matrice de correlation** : Heatmap des correlations entre toutes les variables numeriques
- **Correlations fortes** : Identification de 48 paires de variables avec $|r| > 0.7$
- **Scatterplots** : Visualisation des paires les plus fortement correlees
- **Distribution des variables categorielles** : Analyse des variables temporelles (heures de pic)

Visualisations

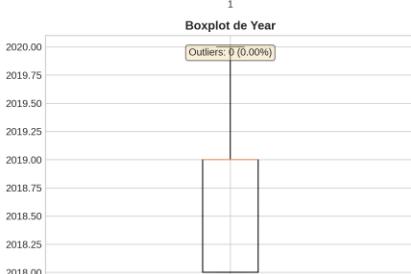
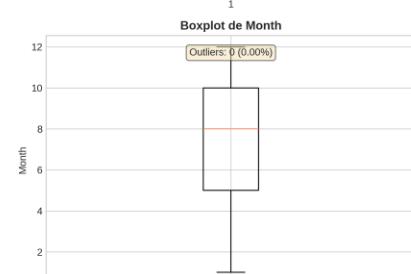
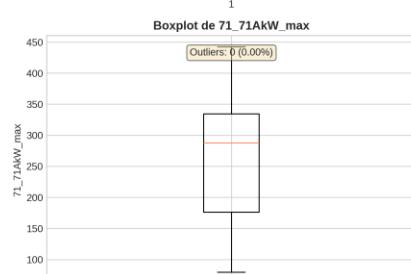
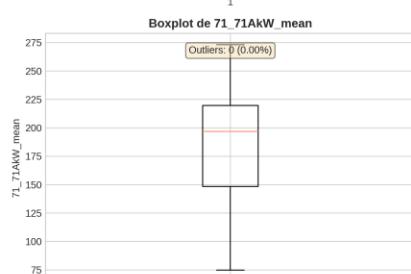
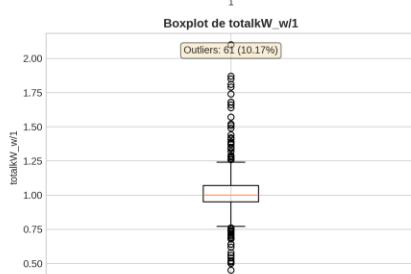
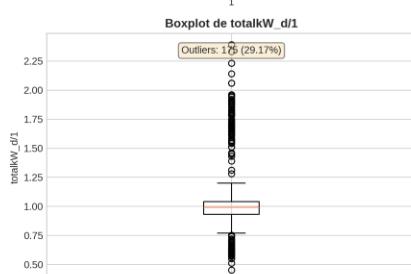
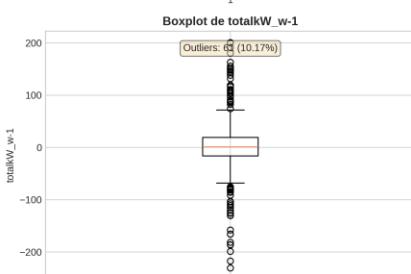
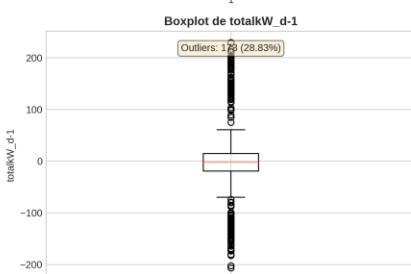
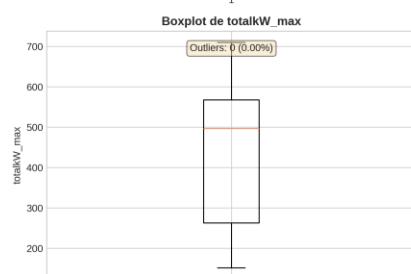
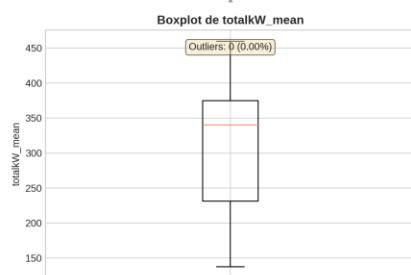
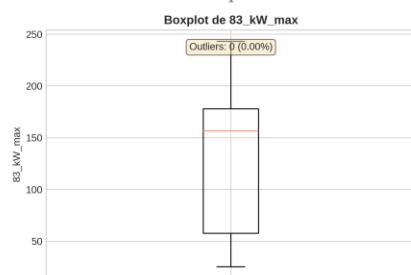
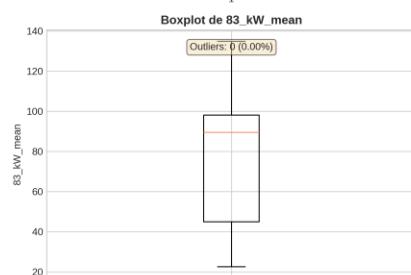
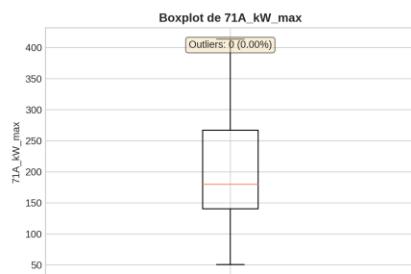
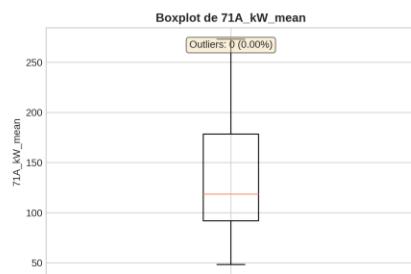
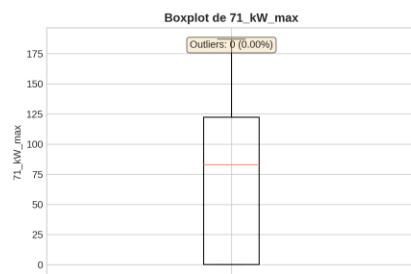
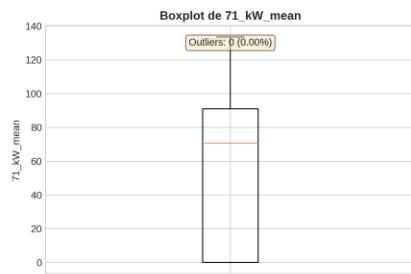
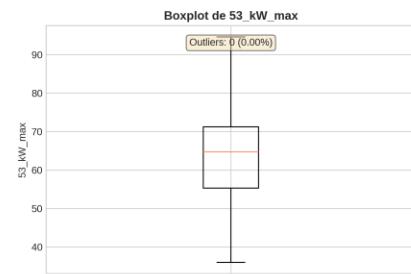
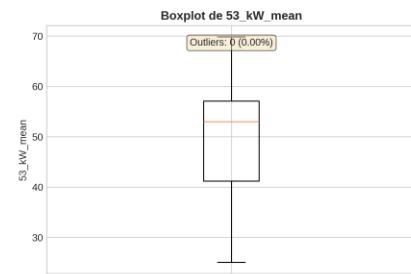
Distribution des variables numeriques :

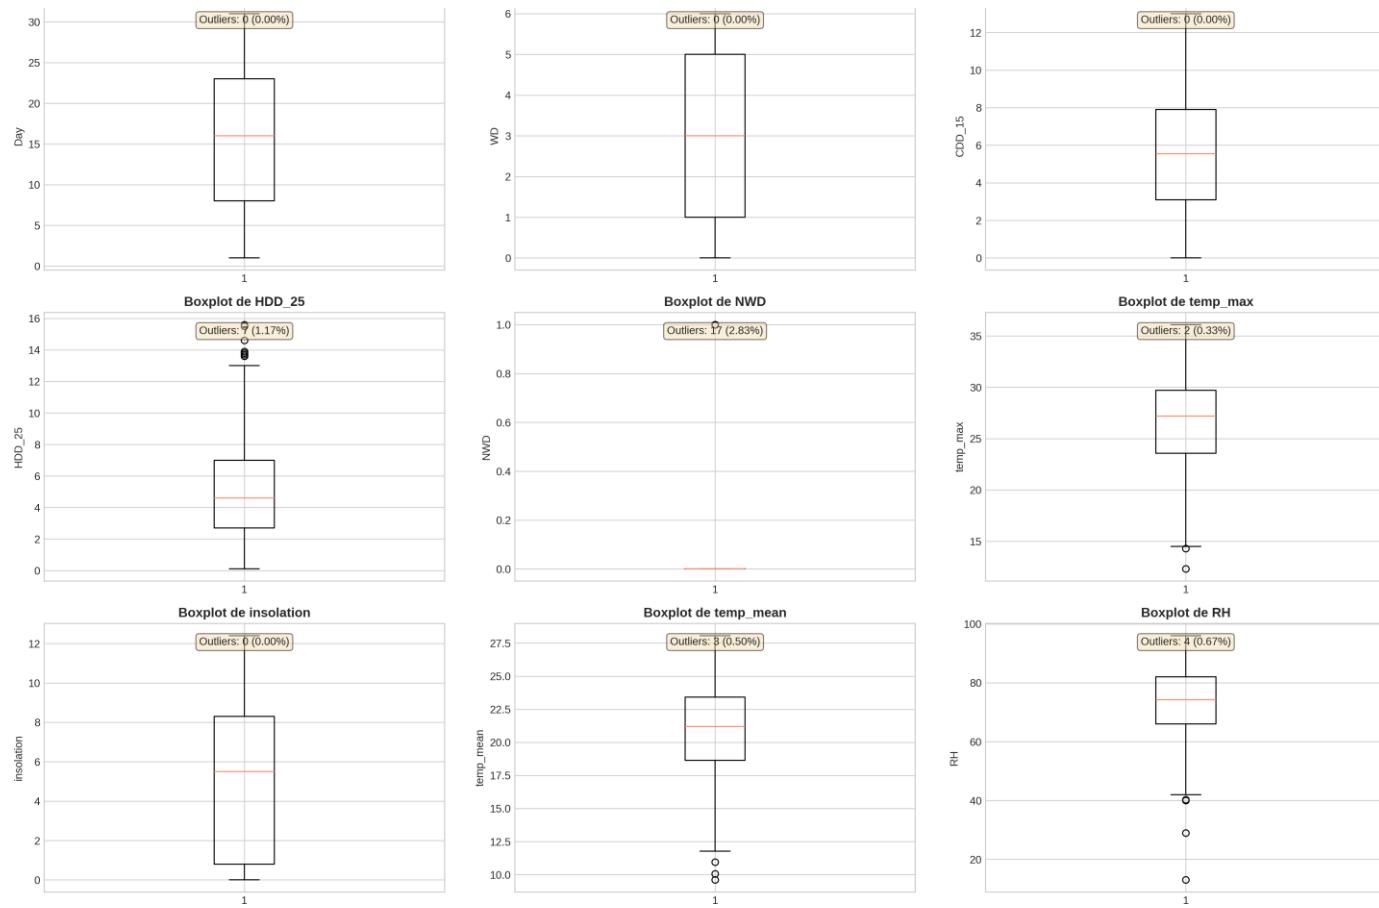






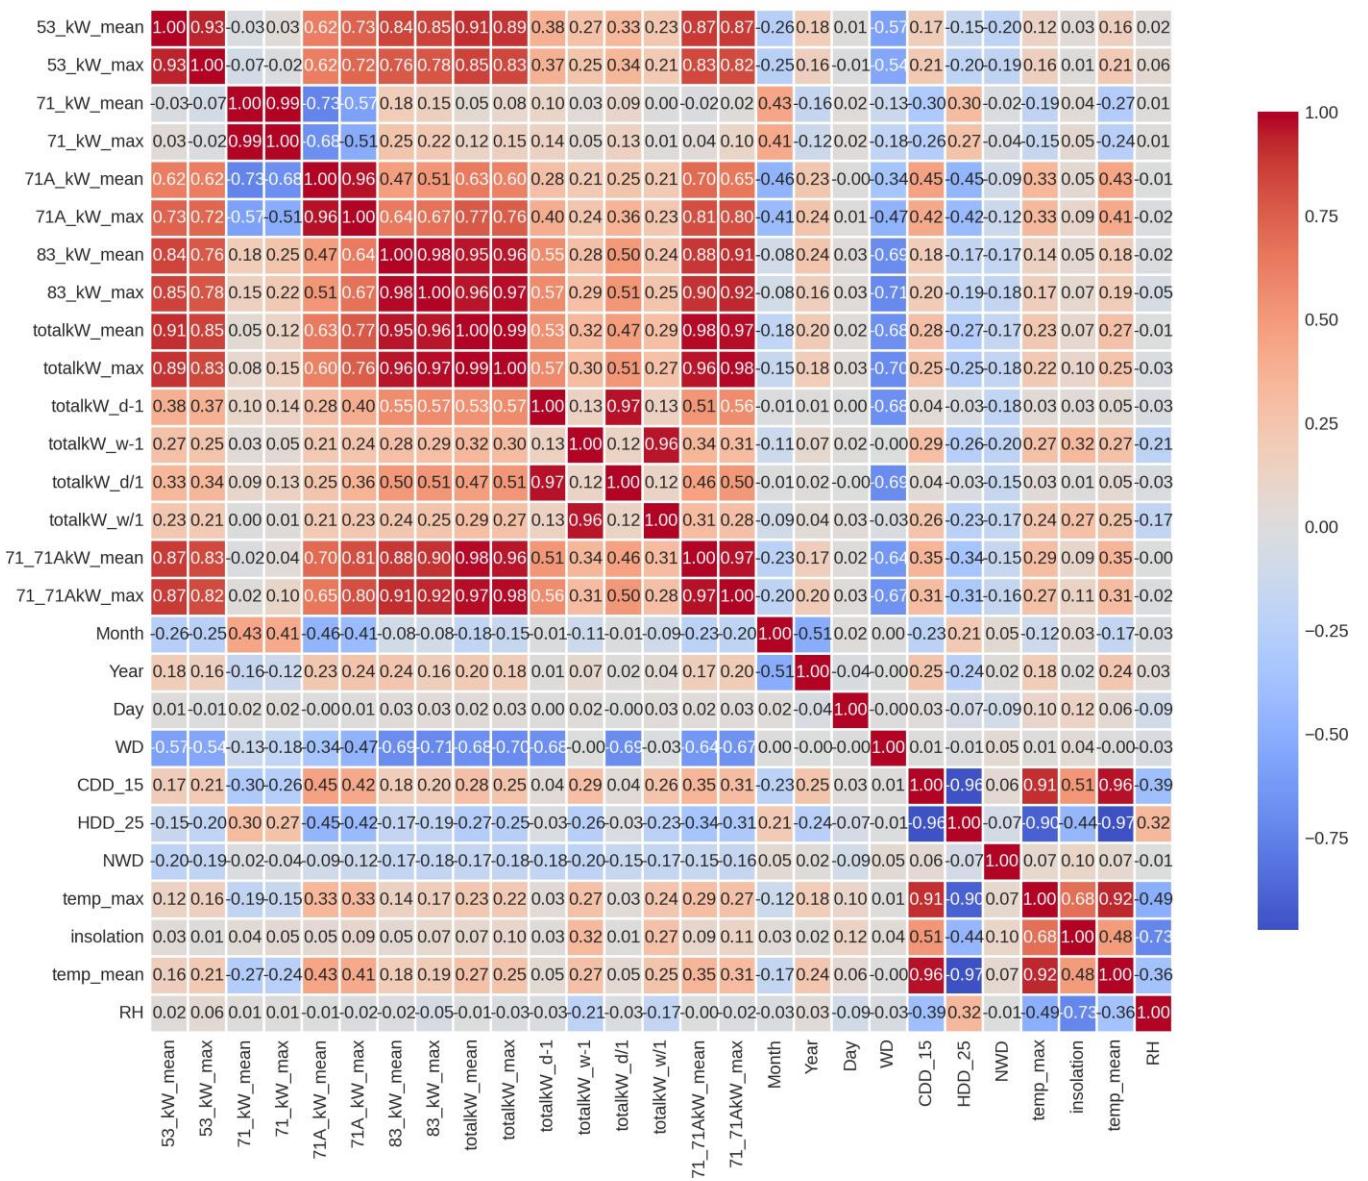
Boxplots pour la detection des outliers :

**Boxplot de Day****Boxplot de WD****Boxplot de CDD_15**

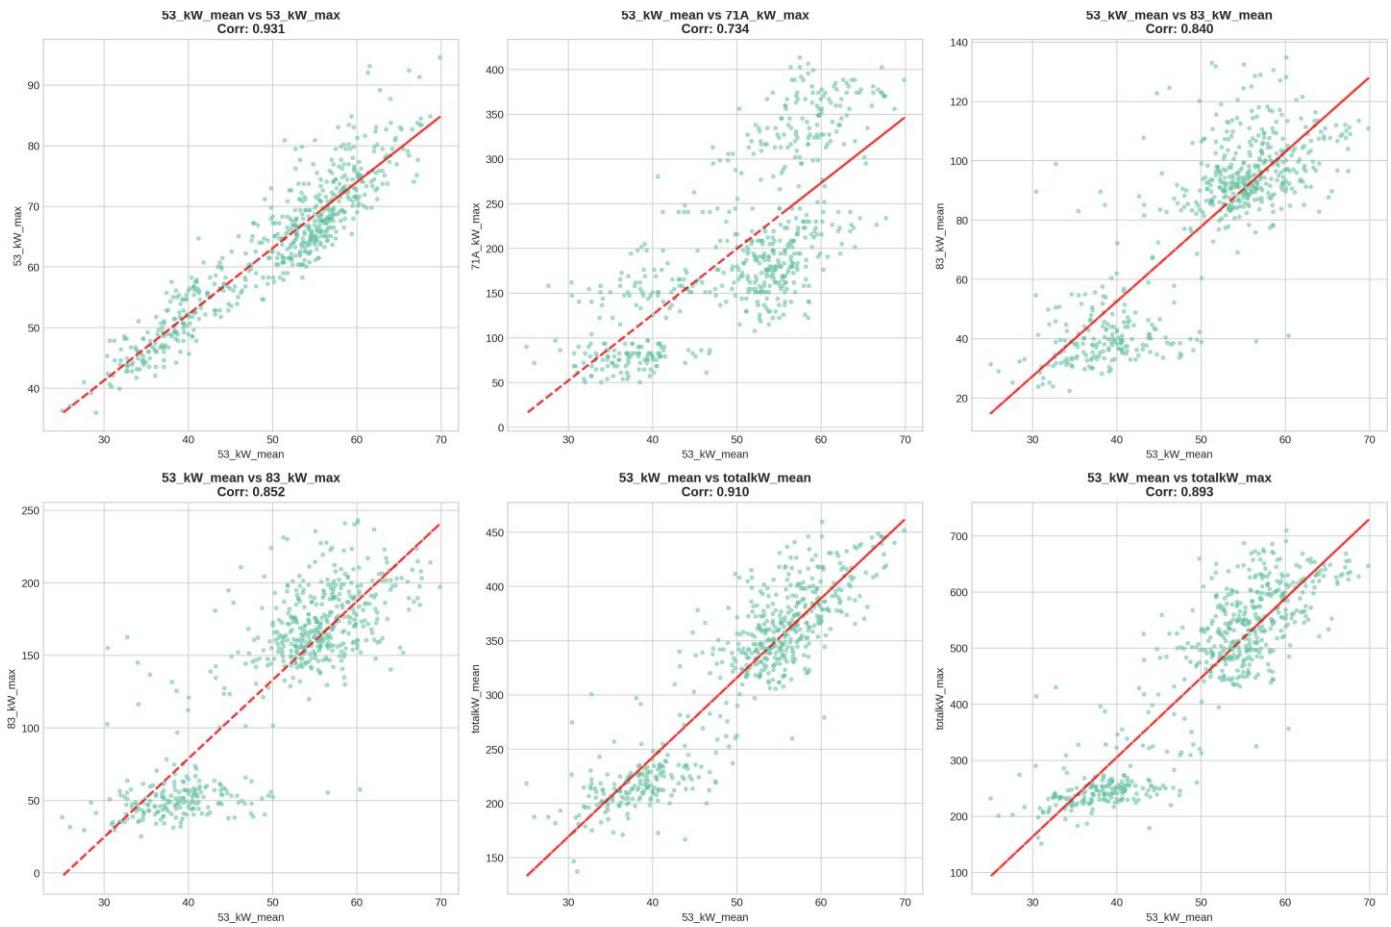


Matrice de corrélation :

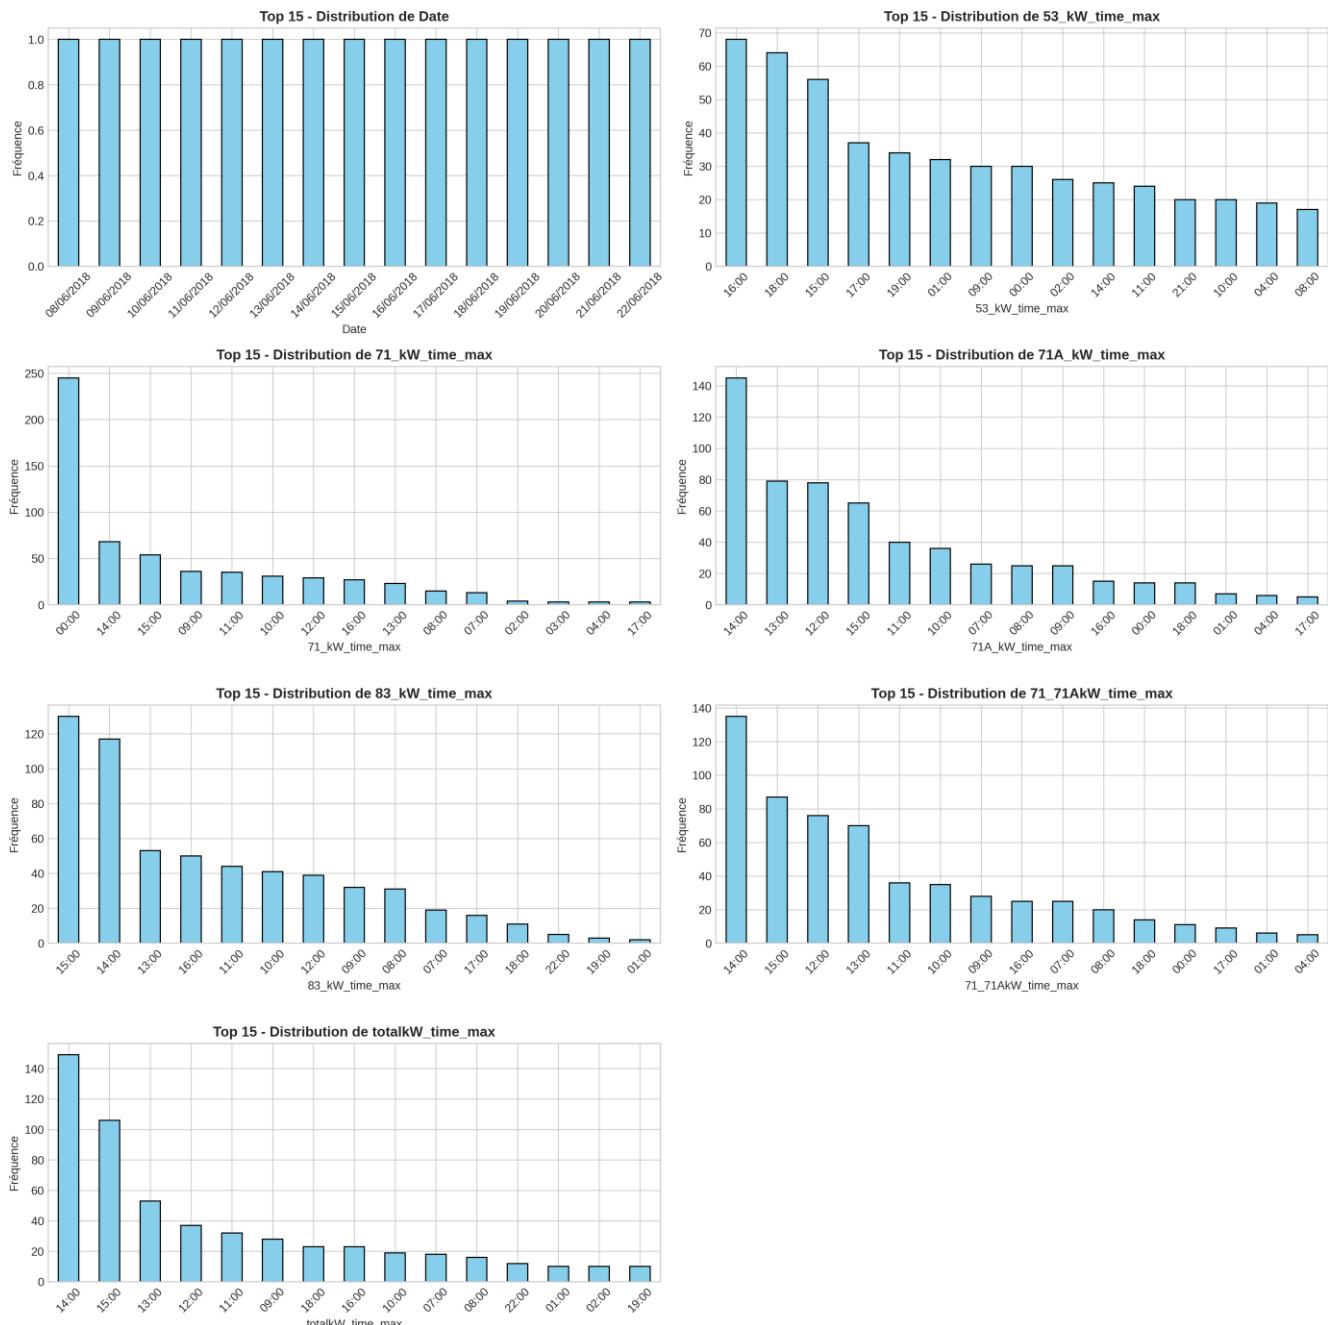
Matrice de Corrélation des Variables Numériques



Scatterplots des corrélations fortes :



Distribution des variables catégorielles :



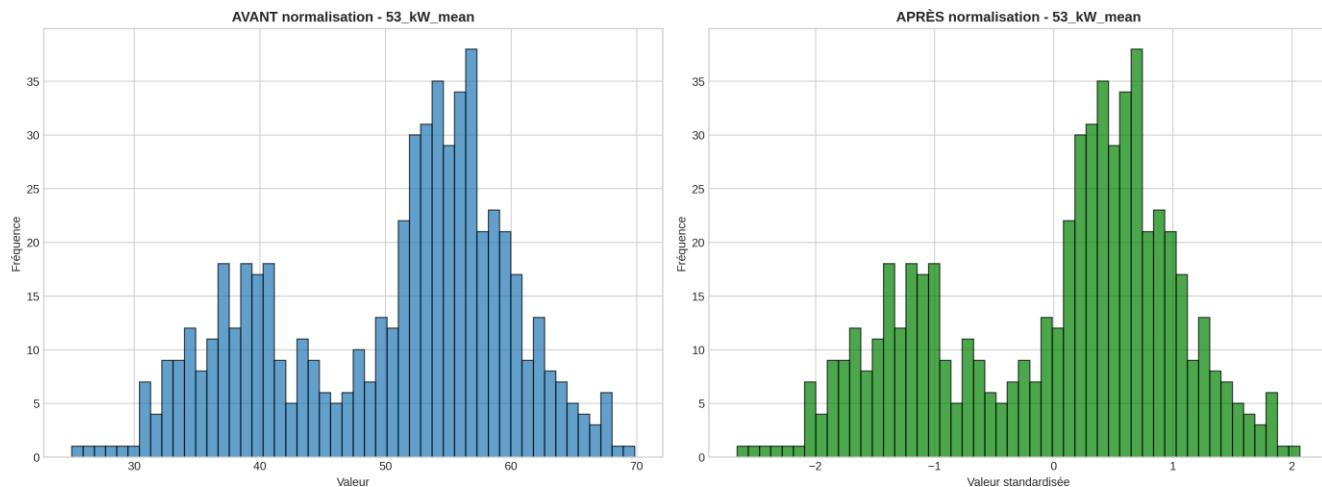
1. Preparation des Donnees (03_preparation_donnees.ipynb)

Ce notebook transforme les donnees brutes en un format exploitable pour la modelisation. Les etapes sont:

- **Suppression des doublons :** Verification et suppression (0 doublons trouves)
- **Gestion des valeurs manquantes :** Imputation par la mediane pour les variables numeriques (totalkW_d-1, totalkW_w-1, totalkW_d/1, totalkW_w/1, insolation)
- **Traitement des outliers :** Winsorization (plafonnement) de 503 valeurs extremes sur 9 variables avec la methode IQR
- **Encodage des variables categorielles :** Suppression des colonnes temporelles (Date, heures de pic) car trop de categories uniques
- **Normalisation :** Standardisation (Z-score) de toutes les features avec StandardScaler
- **Separation train/test :** 80% entrainement (480 lignes) / 20% test (120 lignes)

- Sauvegarde** : Export des ensembles X_train, X_test, y_train, y_test et du scaler
- Visualisation**

Comparaison avant/apres normalisation :



3. Modelisation ([04_modelisation.ipynb](#))

Ce notebook entraîne et évalue trois modèles de régression pour prédire la consommation électrique totale. Il comprend :

- Modèle 1 - Régression Linéaire** : Modèle de base avec validation croisée 5-fold
- Modèle 2 - Random Forest Regressor** : Modèle d'ensemble avec 100 arbres, profondeur max 15
- Modèle 3 - Gradient Boosting Regressor** : Modèle de boosting avec taux d'apprentissage 0.1
- Evaluation** : Métriques R², RMSE, MAE et MAPE pour chaque modèle
- Comparaison** : Tableau et graphiques comparatifs des performances
- Importance des variables** : Identification des features les plus influentes pour chaque modèle
- Analyse des résidus** : Distribution des erreurs de prédiction
- Sauvegarde** : Export des modèles entraînés au format [.pkl](#)

Résultats

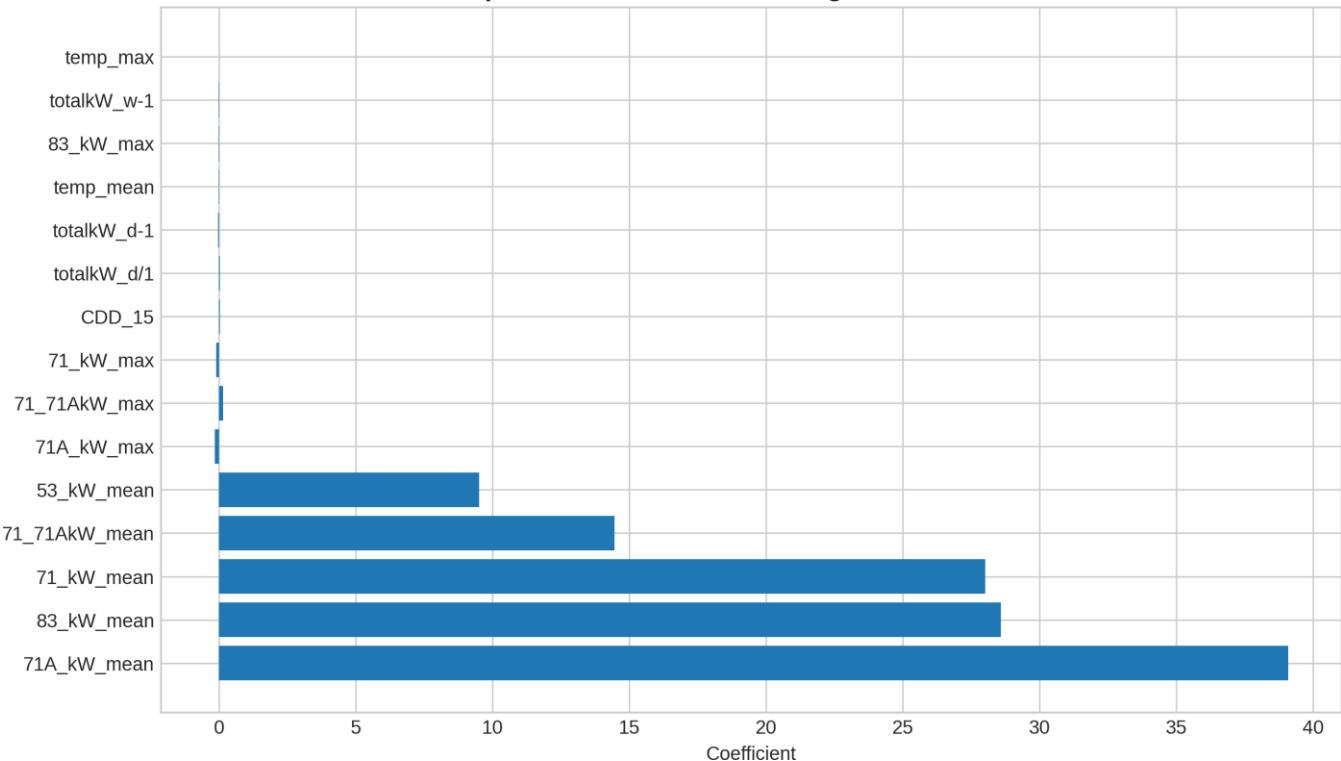
Modèle	R ²	RMSE	MAE	MAPE (%)
Linear Regression	1.0000	0.0828	0.0662	0.02
Random Forest	0.9934	6.0606	4.1775	1.38
Gradient Boosting	0.9960	4.7214	3.2165	1.07

Meilleur modèle : Régression Linéaire (R² = 1.0000)

Visualisations

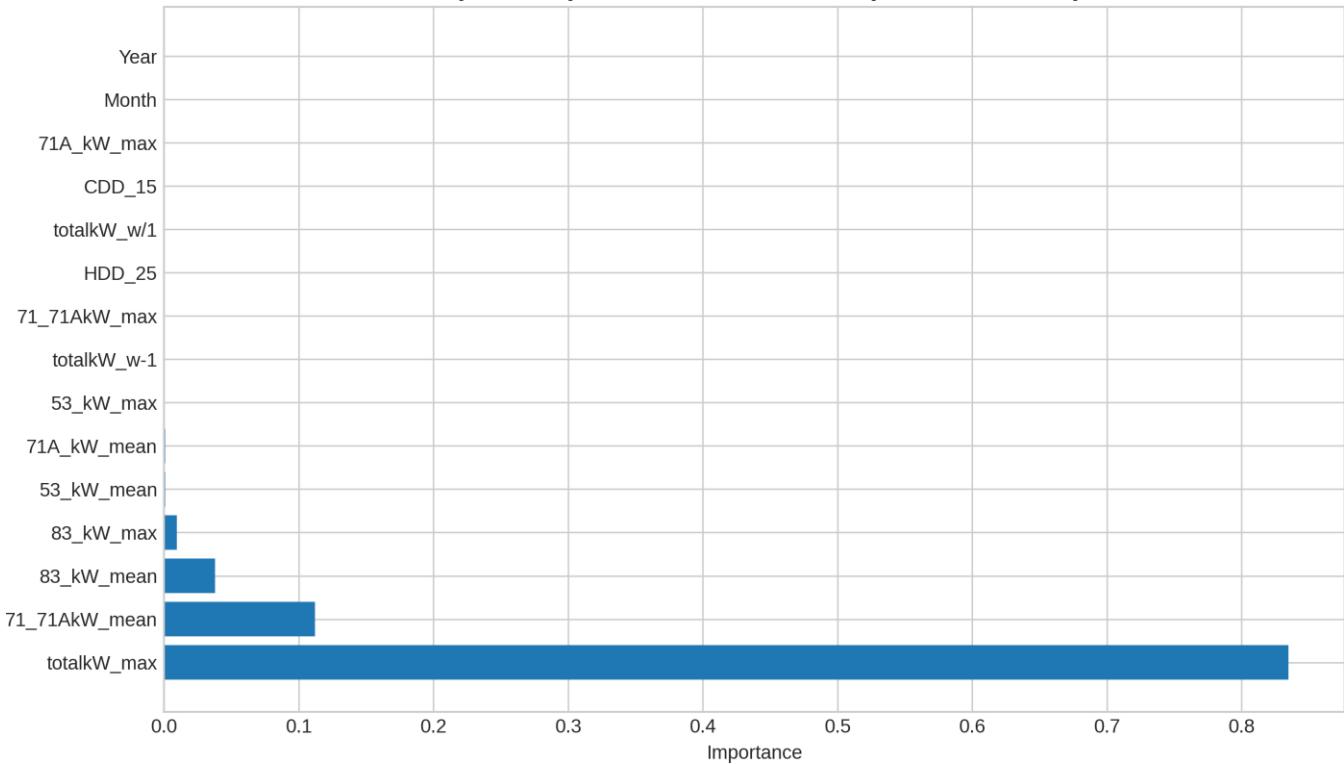
Coefficients de la régression linéaire :

Top 15 - Coefficients de la Régression Linéaire



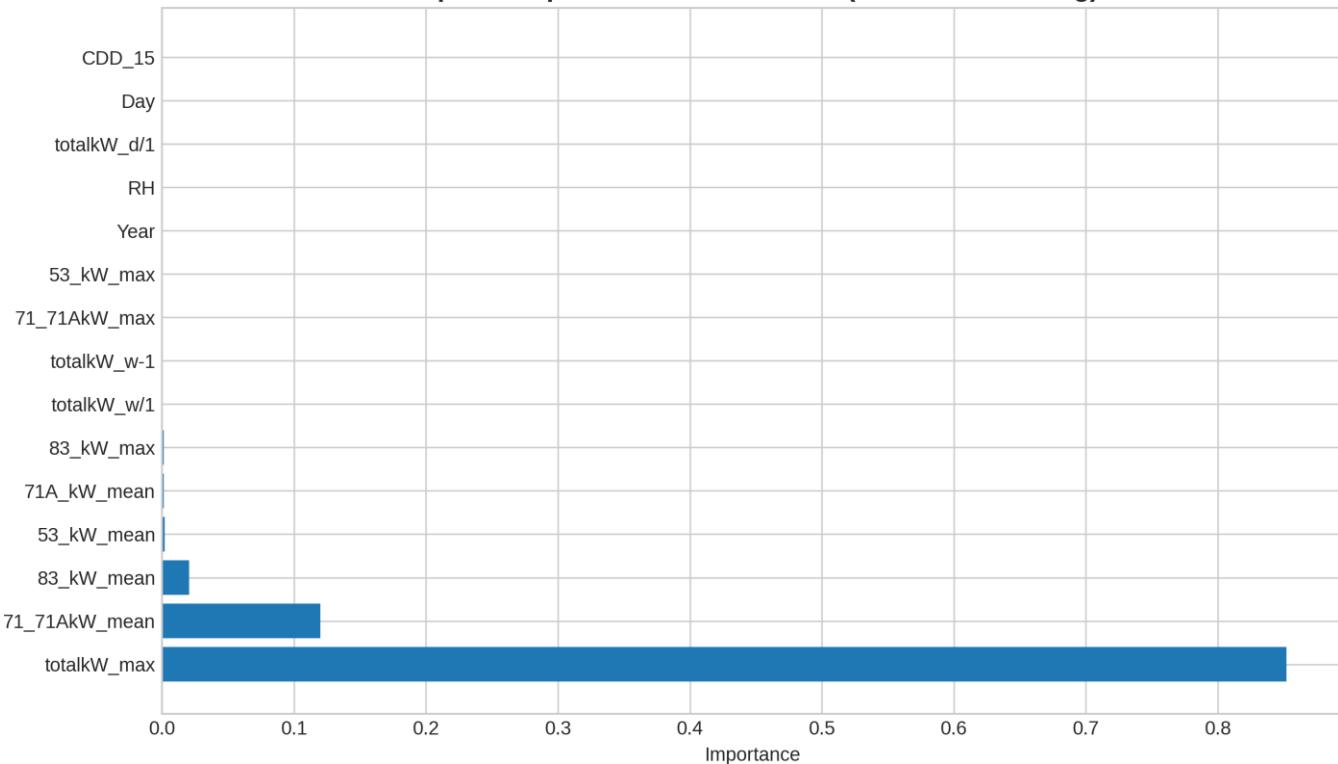
Importance des variables - Random Forest :

Top 15 - Importance des Variables (Random Forest)

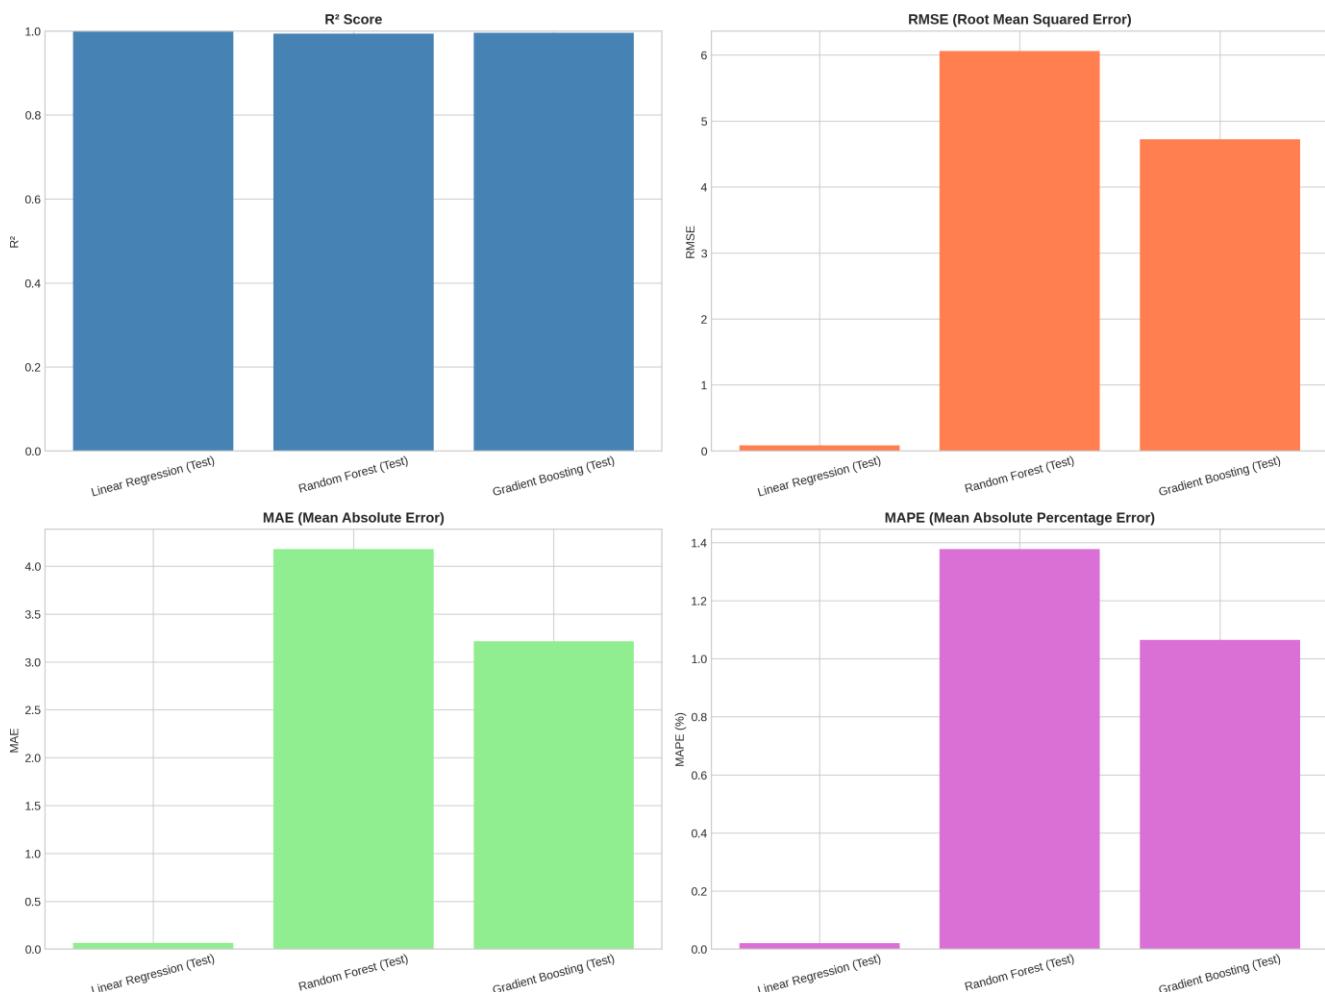


Importance des variables - Gradient Boosting :

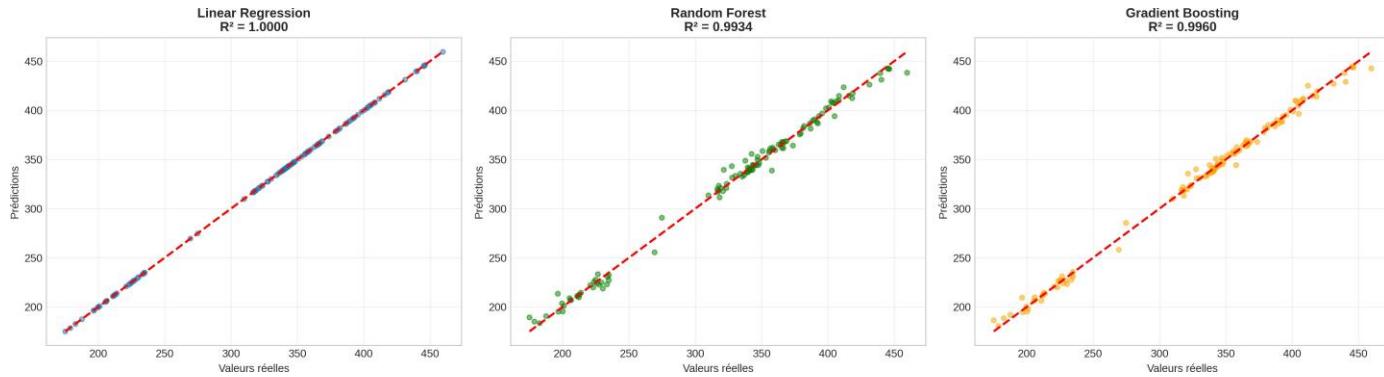
Top 15 - Importance des Variables (Gradient Boosting)



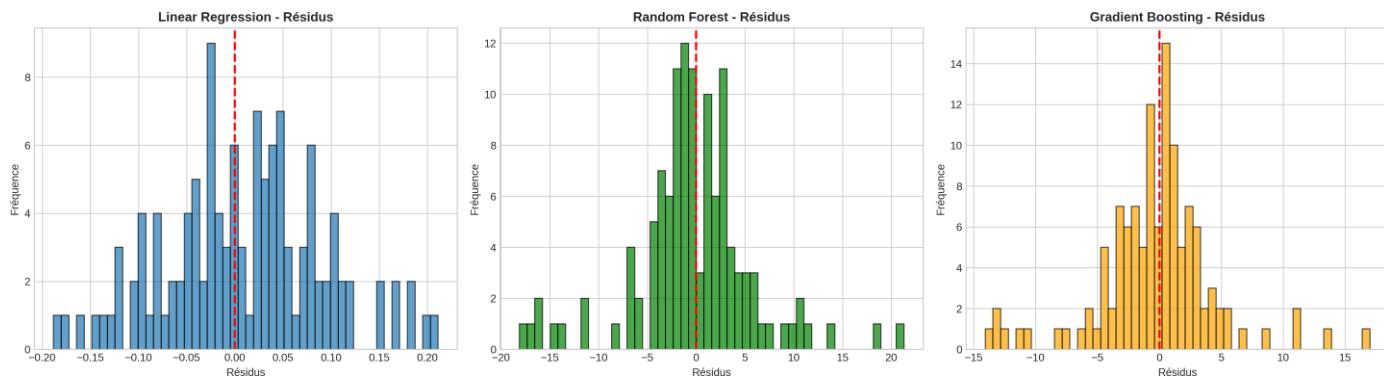
Comparaison des modèles :



Predictions vs Valeurs réelles :



Distribution des residus :



Technologies Utilisees

- Python 3
- Pandas / NumPy : Manipulation et traitement des données
- Matplotlib / Seaborn : Visualisations graphiques
- Scikit-learn : Modélisation (LinearRegression, RandomForestRegressor, GradientBoostingRegressor)
- SciPy : Analyses statistiques
- Joblib : Sauvegarde des modèles

Installation

```
pip install -r requirements.txt
```

Utilisation

Exécuter les notebooks dans l'ordre :

1. `01_collecte_donnees.ipynb` - Chargement et exploration initiale
2. `02_analyse_exploratoire_EDA.ipynb` - Analyse exploratoire et visualisations
3. `03_preparation_donnees.ipynb` - Nettoyage et préparation des données
4. `04_modelisation.ipynb` - Entraînement et évaluation des modèles